LAPORAN DISKUSI DATA PELANGGAN

Persiapan data untuk analisis e-commerce dan prediksi churn

1. Ringkasan

Laporan ini merangkum pembahasan tentang file data proyek di folder simulation. Empat file sumber berisi informasi pelanggan, transaksi, ringkasan pendapatan bulanan, dan ringkasan produk. File customer_ml_dataset.csv merupakan data pelanggan yang telah disiapkan untuk pemodelan, lalu dibagi menjadi data train dan test.

2. File data sumber

customers.csv - 8.000 baris

Satu baris mewakili satu pelanggan. Kolom berisi customer_id; negara, usia, gender, dan membership_tier; tanggal registrasi; jumlah serta nilai belanja; jarak sejak pembelian terakhir; kategori dan perangkat favorit; metode pembayaran dan kanal akuisisi; ulasan, retur, wishlist, langganan newsletter; serta churned sebagai label churn (1 atau 0).

orders.csv - 25.000 baris

Satu baris mewakili satu pesanan. Data mencakup ID pesanan dan pelanggan, tanggal, produk dan kategori, harga dan kuantitas, subtotal, diskon, ongkos kirim, pajak, total transaksi, metode pembayaran, perangkat, lama pengiriman, status pesanan, retur, rating, serta aktivitas sesi sebelum pembelian.

monthly_revenue.csv - 75 baris

Ringkasan tiap bulan: tahun, bulan, kuartal, jumlah pesanan, pendapatan, rata-rata nilai pesanan dan diskon, return_rate, jumlah pelanggan unik, dan pelanggan baru. Dalam data ini return_rate tercatat nol. Catatan data_prep.py menyebut ringkasan pendapatan memakai pesanan terkirim; analisis retur sebaiknya memakai orders.csv.

product_summary.csv - 140 baris

Ringkasan per produk dan kategori: jumlah pesanan, pendapatan, harga dan rating rata-rata, tingkat retur, diskon rata-rata, dan lama pengiriman rata-rata.

DATA SIAP UNTUK PEMODELAN

3. Dataset pelanggan hasil persiapan

Ketiga CSV berikut memiliki 23 kolom dan satu baris per pelanggan. customer_id dipertahankan agar baris dapat ditelusuri kembali. Tujuh kolom kategorikal adalah country, gender, membership_tier, preferred_category, preferred_device, preferred_payment_method, dan acquisition_channel. Sisanya mencakup 14 kolom numerik, satu kolom ID, dan target churned.

Kolom numerik mencakup age, total_orders, total_spend_usd, avg_order_value_usd, days_since_last_purchase, reviews_given, avg_review_score, returns_made, wishlist_items, newsletter_subscribed, customer_tenure_days, orders_per_year, reviews_per_order, dan returns_per_order. churned adalah target klasifikasi.

File | Baris | Kegunaan
customer_ml_dataset.csv | 8.000 | Dataset pelanggan lengkap setelah persiapan fitur
customer_train.csv | 6.400 | Data untuk melatih model
customer_test.csv | 1.600 | Data untuk mengevaluasi model pada baris terpisah

4. Fitur yang dihitung

customer_tenure_days menghitung lama sejak pendaftaran sampai tanggal snapshot. orders_per_year menghitung pesanan per tahun masa pelanggan. reviews_per_order dan returns_per_order menghitung ulasan atau retur per pesanan; jika total pesanan nol, kedua rasio diisi nol.

5. Alur persiapan

data_prep.py memuat dan memeriksa empat CSV sumber, mengubah kolom tanggal, menentukan snapshot dari tanggal terbaru di pesanan atau registrasi, membuat fitur pelanggan, lalu membagi dataset dengan train_test_split. Pembagian memakai test_size 0.20, random_state 42, dan stratify berdasarkan churned agar proporsi kelas terjaga. Skrip menyimpan dataset lengkap, train, test, dan laporan kualitas data.

6. Contoh membaca baris

Contoh dari customer_ml_dataset.csv: customer C00001 memiliki 4 pesanan, total belanja 286.63 USD, customer_tenure_days 2631, orders_per_year sekitar 0.56, dan churned = 0. Angka ini menggambarkan satu pelanggan; bukan ringkasan seluruh dataset.

Catatan struktur

customer_ml_dataset.csv adalah keseluruhan data setelah persiapan. customer_train.csv dan customer_test.csv adalah dua bagian hasil pemisahan data tersebut. Untuk pembelajaran mesin, customer_id biasanya berfungsi sebagai identitas, sedangkan churned menjadi label yang diprediksi.